

$$\begin{aligned}
J_1 &= [-(\lambda_t - \lambda)e^{-\lambda}]_{\lambda_s}^{\lambda_t} - \int_{\lambda_s}^{\lambda_t} (-1)e^{-\lambda} d\lambda = -0 + (\lambda_t - \lambda_s)e^{-\lambda_s} - (e^{-\lambda_s} - e^{-\lambda_t}) \\
&= he^{-\lambda_s} - (e^{-\lambda_s} - e^{-\lambda_t}) = (h-1)e^{-\lambda_s} + e^{-\lambda_t}, \\
J_2 &= \int_{\lambda_s}^{\lambda_t} (\lambda - \lambda_s)e^{-\lambda} d\lambda = [-(\lambda - \lambda_s)e^{-\lambda}]_{\lambda_s}^{\lambda_t} + \int_{\lambda_s}^{\lambda_t} e^{-\lambda} d\lambda \\
&= -0 + (\lambda_t - \lambda_s)e^{-\lambda_t} + (e^{-\lambda_s} - e^{-\lambda_t}) = he^{-\lambda_t} + e^{-\lambda_s} - e^{-\lambda_t} = (h-1)e^{-\lambda_t} + e^{-\lambda_s}.
\end{aligned}$$

最终得：

$$I = \frac{1}{h} [(h-1)e^{-\lambda_s} + e^{-\lambda_t}] k_1 + [(h-1)e^{-\lambda_t} + e^{-\lambda_s}] k_2.$$

将近似积分项代入 (272)，得最终近似公式：

$$\mathbf{x}_t \approx \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \alpha_t \cdot \frac{1}{h} [(h-1)e^{-\lambda_s} + e^{-\lambda_t}] k_1 + [(h-1)e^{-\lambda_t} + e^{-\lambda_s}] k_2, \quad (279)$$

其中 k_1, k_2 由前述公式给出。

值得注意的是，正如原文所指出，4 阶及以上准确度的指数龙格-库塔法，由于求近似积分点 k_i 所需神经网络调用步骤过多，因此虽然相同迭代次数下精确度更高，但相同神经网络函数调用次数 (NFE) 下，效果反而不如低阶方法，因此不加采用。

5.2 DPM-Solver++

5.3 DPM-Solver-v3

6 习题课 1: Distillation of Diffusion Models

本节探讨 Diffusion Models 的蒸馏，这事实上仍然是初等概率论的习题课。

6.1 Score Distillation

Score Distillation 是让两个分布间 f-散度尽量接近的 distribution matching。记号约定：

- p_{teacher} 是 pretrained teacher model 的分布，认为（近似）等于 p_{data} ；
- p_{student} 是学生模型 G_θ 的分布。对于为模型加速服务的蒸馏任务，学生模型一般是 one/few-step model。
- 如无特殊说明，则 $\mathbf{x}_0 = G_\theta(\mathbf{z})$, $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是学生模型的样本； $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是对学生模型生成结果混以独立的标准高斯所得结果。
- $s_{\text{teacher}}(\mathbf{x}_t, t)$ 是 $\mathbf{x}_t$ 代入 teacher model 分布的 score 函数，这里在第一条约定下，认为（近似）等于 $\mathbf{x}_t$ 代入数据分布的 score 函数。 $s_{\text{student}}(\mathbf{x}_t, t)$ 是 $\mathbf{x}_t$ 代入 p_{student} 分布的 score 函数， $\hat{s}_{\text{student}}(\mathbf{x}_t, t)$ 是 $\mathbf{x}_t$ 代入用另一个独立于 teacher model 和 student model G_θ 的 score model 估计出的 p_{student} 分布的 score 函数。
- 注意涉及三个模型：teacher model 是一个 score model；student model G_θ 是目标训练对象；还有拟合 student model 分布的另一个 score model，这个模型要在 student model 分布上 online 训练。
- 如无特殊说明，则 $q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$ 是 forward diffusion transition kernel。

$$\theta^* = \min_{\theta} \mathbb{E}_t [D_f(p_{\text{student}}(\mathbf{x}_t) || p_{\text{teacher}}(\mathbf{x}_t))], \quad D_f(p_{\text{student}}(\mathbf{x}_t) || p_{\text{teacher}}(\mathbf{x}_t)) = \mathbb{E}_{p_{\text{student}}(\mathbf{x}_t)} \left[f\left(\frac{p_{\text{teacher}}(\mathbf{x}_t)}{p_{\text{student}}(\mathbf{x}_t)}\right) \right]. \quad (280)$$

记 $r := \frac{p_{\text{teacher}}(\mathbf{x}_t)}{p_{\text{student}}(\mathbf{x}_t)}$, 则

- DMD (Sec. 6.1.1) 是 KL 散度, $f(r) = -\log(r)$;
- SiD (Dec. 6.1.2) 是 Fisher 散度, $f(r) = \|\nabla_{\mathbf{x}_t} \log r\|^2$.

注意, 由于优化 G_{θ} 须从 G_{θ} 采样, 因此这里的散度均为 reverse divergence, 因此存在 Mode-Seeking 问题, (没达到理论最优的) p_{student} 较之 p_{teacher} 会 lose diversity.

注 6.1.1. 实际上从 teacher 采样, 让 student model 做 SiD loss, 则原则上 forward divergence 也能更新 student? 这一策略有何问题?

这样一来, student 成了一个 few-step score model, 根据本节最后探讨 Remark. 6.1.4, 这存在相当大的理论误差。

6.1.1 Distribution Matching Distillation

VSD/DMD 通过最小化 Reverse KL Divergence 来让 student 分布 match teacher 分布. 先来讨论 1-step 生成, 记 Generator 为 G_{θ} .

$$D_{\text{KL}}(p_{\text{student}}(\mathbf{x}_0) || p_{\text{teacher}}(\mathbf{x}_0)) = \mathbb{E}_{\mathbf{x}_0 \sim p_{\text{student}}} [\log \left(\frac{p_{\text{student}}(\mathbf{x}_0)}{p_{\text{teacher}}(\mathbf{x}_0)} \right)] \quad (281)$$

$$= \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [-(\log p_{\text{teacher}}(G_{\theta}(\mathbf{x}_T)) - \log p_{\text{student}}(G_{\theta}(\mathbf{x}_T)))], \quad (282)$$

SGD:

$$-\nabla_{\theta} D_{\text{KL}}(p_{\text{student}}(\mathbf{x}_0) || p_{\text{teacher}}(\mathbf{x}_0)) = \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [(\nabla_{\theta} \log p_{\text{teacher}}(G_{\theta}(\mathbf{x}_T)) - \nabla_{\theta} \log p_{\text{student}}(G_{\theta}(\mathbf{x}_T))) \nabla_{\theta} G_{\theta}(\mathbf{x}_T)] \quad (283)$$

$$= \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [(s_{\text{teacher}}(G_{\theta}(\mathbf{x}_T)) - s_{\text{student}}(G_{\theta}(\mathbf{x}_T))) \nabla_{\theta} G_{\theta}(\mathbf{x}_T)]. \quad (284)$$

这里 $\nabla_{\theta} G_{\theta}(\mathbf{x}_T)$ 可以直接求; $s_{\text{teacher}}(G_{\theta}(\mathbf{x}_T))$ 对于 score model 可直接令 $t = 0$ 获得, $s_{\text{student}}(G_{\theta}(\mathbf{x}_T))$ 把 teacher model 微调到 p_{student} 上即可. 后者显然在协同优化中不稳定, DMD2 提出, 这个模型的梯度更新频率是 G_{θ} 的 $c > 1 \in \mathbb{N}$ 倍, 例如 5 (理想情况是 $c \rightarrow \infty$, 工程上考虑训练效率).

显然有 NCSN 中的问题, 也可以 NCSN 解决: 将 Eq.(281) 换成

$$D_{\text{KL}}(p_{\text{student}}(\mathbf{x}_t) || p_{\text{teacher}}(\mathbf{x}_t)), \quad (285)$$

其中

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma \mathcal{N}(\mathbf{0}, \mathbf{I}) = \alpha_t G_{\theta}(\mathbf{x}_T) + \sigma \mathcal{N}(\mathbf{0}, \mathbf{I}), t \in [0, T]. \quad (286)$$

则梯度为

$$\mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [(s_{\text{teacher}}(\mathbf{x}_t) - s_{\text{student}}(\mathbf{x}_t)) \nabla_{\theta} \mathbf{x}_t] \quad (287)$$

$$\approx \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [(s_{\text{teacher}}(\mathbf{x}_t, t) - \hat{s}_{\text{student}}(\mathbf{x}_t, t)) \nabla_{\theta} \mathbf{x}_t], \quad (288)$$

即用 diffusion model 近似. 这里要说明如此替换与 Eq.(281) 等价:

命题 6.1.2 (Gaussian transition kernel and the margin distribution).

$$D_{\text{KL}}(p_1(\mathbf{x})||p_2(\mathbf{x})) = 0 \Leftrightarrow D_{\text{KL}}(p_1(\alpha\mathbf{x} + \sigma\epsilon)||p_2(\alpha\mathbf{x} + \sigma\epsilon)) = 0, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (289)$$

证明. 据 Corollary 1.3.5 显然. ■

Few-step G_θ . 为了消除 exposure bias, 对于 few-step G_θ , 先从 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 采样到要训练的 timestep, 然后再一步生成得到 $\mathbf{x}_{0,\tau} = G_\theta(\mathbf{x}_T, \tau)$, where $G_\theta(\mathbf{x}_T, \tau)$ is generated with the following timesteps:

$$T \rightarrow \tau_1 \rightarrow \tau_2 \rightarrow \cdots \rightarrow \tau \rightarrow 0, \quad (290)$$

其中梯度只对 $\tau \rightarrow 0$ 这一步计算。

6.1.2 Score identity Distillation

我们定义 $\mathbf{x}_0 = G_\theta(\mathbf{z}), \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t^2 \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 则类似于 DMD, 据 Proposition. 6.1.2 训练 $p_{\text{student}}(\mathbf{x}_0) := p_\theta(\mathbf{x}_0) \rightarrow p_{\text{data}}(\mathbf{x}_0)$ 等价于训练 $p_{\text{student}}(\mathbf{x}_t) \rightarrow p_{\text{data}}(\mathbf{x}_t), \quad \forall t \in [0, 1)$. 具体策略是训练 $\log p_{\text{student}} = \log p_{\text{teacher}}$, 这里总体思想是 minimize $\mathbb{E}_z \|s_{\text{student}}(\mathbf{x}_t, t) - s_{\text{teacher}}(\mathbf{x}_t, t)\|^2$, 仍类似地用另一个 diffusion model $\hat{s}_{\text{student}}(\mathbf{x}_t, t)$ online 学习 $s_{\text{student}}(\mathbf{x}_t, t)$:

$$\mathcal{L}_{\text{supposed}} = \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\|s_{\text{teacher}}(\mathbf{x}_t, t) - s_{\text{student}}(\mathbf{x}_t, t)\|^2] \quad (291)$$

$$\approx \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\|s_{\text{teacher}}(\mathbf{x}_t, t) - \hat{s}_{\text{student}}(\mathbf{x}_t, t)\|^2] \quad (292)$$

$$=: \mathcal{L}_1. \quad (293)$$

这也就是 DMD 梯度 updates 去掉 $\nabla_\theta G_\theta(\mathbf{z})$ (但是注意, 这里是 loss, DMD Eq.(284) 是梯度; SiD loss 求梯度后会在 score 加梯度并引入 $\nabla_\theta G_\theta(\mathbf{z})$). 这个差别不是 SiD 区别于 DMD 的重点贡献, 核心的创见在于如何协调两个同时优化的模型。

Bilevel Optimization Problem, 双层优化问题. Bilevel Optimization (双层优化) 包含了两个阶层的优化任务, 一个优化问题嵌套在另一个优化问题内。外层的优化问题通常称为 leader's (upper level) optimization problem, 内层的优化问题通常称为 follower's (or lower level) optimization problem。二阶层优化可在一定程度上看作是一个有约束优化问题, 因为下层优化问题可看作是上层优化问题的约束。

这类问题中有两类优化变量: leader's (upper level) decision vectors and follower's (lower level) decision vectors。在我们这个问题中, 上层优化是 $G_\theta \rightarrow \text{data}$, 下层优化是 $\hat{s}_{\text{student}}(\mathbf{x}_t, t) \rightarrow s_{\text{student}}(\mathbf{x}_t, t)$. DMD2 通过 $c = 5$ 近似 $c \rightarrow \infty$ 来模拟每次都是下层问题得到完整优化。

回到 SiD, 我们这里先给出 $\mathcal{L}_1$ 与真正 loss 的解析差异:

$$\mathcal{L}_{\text{supposed}} = \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\|s_{\text{teacher}}(\mathbf{x}_t, t) - s_{\text{student}}(\mathbf{x}_t, t)\|^2], \quad (294)$$

$$\mathcal{L}_1 = \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\|s_{\text{teacher}}(\mathbf{x}_t, t) - \hat{s}_{\text{student}}(\mathbf{x}_t, t)\|^2], \quad (295)$$

$$\begin{aligned} \Rightarrow \mathcal{L}_1 &= \mathcal{L}_{\text{supposed}} + \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\|s_{\text{student}}(\mathbf{x}_t, t) - \hat{s}_{\text{student}}(\mathbf{x}_t, t)\|^2] \\ &\quad + 2 \underbrace{(s_{\text{student}}(\mathbf{x}_t, t) - \hat{s}_{\text{student}}(\mathbf{x}_t, t))^\top (s_{\text{teacher}}(\mathbf{x}_t, t) - s_{\text{student}}(\mathbf{x}_t, t))}_{\text{这一项与上层优化的 } s_{\text{teacher}}(\mathbf{x}_t, t) - s_{\text{student}}(\mathbf{x}_t, t) \text{ 有关}}. \end{aligned} \quad (296)$$

可见, 当 $s_{\text{student}}(\mathbf{x}_t, t) \neq \hat{s}_{\text{student}}(\mathbf{x}_t, t)$ 时, $\mathcal{L}_1$ 与 $\mathcal{L}_{\text{supposed}}$ 的差异不能被 $s_{\text{student}}(\mathbf{x}_t, t) - \hat{s}_{\text{student}}(\mathbf{x}_t, t)$ 限制住, 上层优化的 $s_{\text{teacher}}(\mathbf{x}_t, t) - s_{\text{student}}(\mathbf{x}_t, t)$ 也会影响近似准确程度. 尤其是在训练初期, 若 $s_{\text{teacher}}(\mathbf{x}_t, t) - s_{\text{student}}(\mathbf{x}_t, t)$ 非常大, 则下层优化误差会被严重放大, 这是影响上层优化的关键问题。

下面我们采取 Eq. (291) 的等价形式来替代之, 并说明这个形式下的误差与上层优化无关:

命题 6.1.3.

$$\mathcal{L}_{\text{supposed}} = \mathbb{E}_{\mathbf{x}_t \sim p_{\text{student}}(\mathbf{x}_t)} [\|s_{\text{teacher}}(\mathbf{x}_t, t) - s_{\text{student}}(\mathbf{x}_t, t)\|^2] \quad (297)$$

$$= \mathbb{E}_{\mathbf{x}_t \sim q(\mathbf{x}_t | \mathbf{x}_0), \mathbf{x}_0 \sim p_{\text{student}}(\mathbf{x}_0)} [(s_{\text{teacher}}(\mathbf{x}_t) - s_{\text{student}}(\mathbf{x}_t))^\top \frac{(f_{\text{teacher}}(\mathbf{x}_t, t) - \mathbf{x}_0)}{\sigma_t^2}], \quad (298)$$

其中 $f_{\text{teacher}}(\mathbf{x}_t, t)$ 是 $\mathbb{E}_{\mathbf{x}_0 \sim p_{\text{student}}(\mathbf{x}_0 | \mathbf{x}_t)} [\mathbf{x}_0 | \mathbf{x}_t]$ 是预测模型, 据 Tweedie Formula Corollary. 1.4.3, 即为

$$f_{\text{teacher}}(\mathbf{x}_t, t) = \frac{\sigma_t^2 s_{\text{teacher}}(\mathbf{x}_t, t) + \mathbf{x}_t}{\alpha_t}. \quad (299)$$

(于是写成 score 形式是 $\mathcal{L}_{\text{supposed}} = \mathbb{E}_{\mathbf{x}_t \sim q(\mathbf{x}_t | \mathbf{x}_0), \mathbf{x}_0 \sim p_{\text{student}}(\mathbf{x}_0)} [(s_{\text{teacher}}(\mathbf{x}_t) - s_{\text{student}}(\mathbf{x}_t))^\top (\frac{s_{\text{teacher}}(\mathbf{x}_t, t)}{\alpha_t} + \frac{\mathbf{x}_t / \alpha_t - \mathbf{x}_0}{\sigma_t^2})]$). 证明留作习题。

在这种等价的 loss 下, 近似误差为

$$\mathcal{L}_2 = \mathcal{L}_{\text{supposed}} + \mathbb{E}_{\mathbf{x}_t \sim q(\mathbf{x}_t | \mathbf{x}_0), \mathbf{x}_0 \sim p_{\text{student}}(\mathbf{x}_0)} [(s_{\text{student}}(\mathbf{x}_t) - \hat{s}_{\text{student}}(\mathbf{x}_t))^\top (s_{\text{teacher}}(\mathbf{x}_t, t) + \frac{\mathbf{x}_t - \mathbf{x}_0}{\sigma_t^2})], \quad (300)$$

与上层优化的误差无关, 由此解决了之前的问题。值得注意的是, SiD 原文最终采用了 $\mathcal{L}_2 - \alpha \mathcal{L}_1$, 这在 **后续工作 FGM/SIM** 中被证明能够消除 stop gradient 带来的误差。

注 6.1.4 (关于直接回归 $\mathbf{x}_0$). 朴素想法是直接训练模型预测 $\mathbf{x}_0$:

$$\theta^* = \min_{\theta} \mathbb{E} \|f_{\theta}(\mathbf{z}) - \mathbf{x}_0\|^2, \quad (301)$$

或其加噪后的版本

$$\theta^* = \min_{\theta} \mathbb{E} \|f(\mathbf{x}_t, t) - \mathbf{x}_0\|^2, \quad (302)$$

如果这样实际上可行, 则不论 Consistency Models 还是 Score Distillation 都将失去意义。事实上这样的回归损失的缺欠在于哪方面?

提出这一问题说明对概率机器学习没有入门, 以为单个点的函数拟合等同于分布的拟合。考察 Eq. (301) 的解, 我们有以下命题:

命题 6.1.5 (最优均方误差). 设随机变量对 (X, Y) 定义在同一概率空间上, X 取值于可测空间 $\mathcal{X}$, Y 取值于 $\mathbb{R}^d$, 且 $\mathbb{E} \|Y\|^2 < \infty$. 考虑均方误差下的点预测问题

$$\inf_{f: \mathcal{X} \rightarrow \mathbb{R}^d} \mathbb{E} \|f(X) - Y\|^2.$$

则其 (几乎处处) 唯一的极小化函数为

$$f^*(x) = \mathbb{E}[Y | X = x], \quad x \in \mathcal{X}.$$

事实上均方误差最小准则正是条件期望的另一个定义。**这里必须注意**, $\mathbb{E}[\mathbf{x}_0 | \mathbf{x}_t] \approx p(\mathbf{x}_0)$, **也不是** $\mathbb{E}[\mathbf{x}_0]$, 而是**给定 $\mathbf{x}_t$ 下的条件均值**。均值反映于图像上自然是糊的。

一个自然的问题是, 真正的 one/few-step Score Distilled 概率生成模型为什么能够训练好 (Few-step 模型如果每个 timestep 的 $\mathbf{x}_0$ -prediction 是建模 $\mathbb{E}[\mathbf{x}_0 | \mathbf{x}_t]$, 那 few-step 必然存在巨大的误差)? 这是因为对于 score distillation, 我们优化的目标和 one-step 一致, 即采用另一个模型计算分布的 score, 去显式优化和目标分布之间的 f-散度, 也就是说其优化目标与 diffusion model 完全不同。

值得注意的是，这并不强求 $G_\theta(\mathbf{z}_t, t)$ 的语义。无论是类似于 DM, 建模分布参数然后从分布采样, 还是类似于 CM 的点映射, 形式都无所谓。真正的关键是, **不要做 MSE loss/score matching, 而要显式最小化 f-散度**。

一个例子: few-step DMD 一个类型 (不妨命名为 CM-type) 是, 每一个 t 下, 都是要点到点映射, $f_\theta(\mathbf{x}_t, t) = \mathbf{x}_0 \sim p_{\text{data}}(\mathbf{x}_0)$, 增加 step 是相当于让许多个 one-step 组合起来。如此, 采样必须一步生成 $t = 0$, 然后加噪回去再采样, 即 $T \rightarrow 0 \rightarrow T-1 \rightarrow 0 \rightarrow \dots \rightarrow 1 \rightarrow 0$ 。

那么, DMD2 中为了消除 training-inference gap 而规定 noisy input 必须是上步生成的干净结果加噪, 相对于 GT 加噪, 有原则性的问题吗? 事实上这只是消除 exposure bias 的工程技巧: 假设达到最优解, 则上一步的生成结果必然与 GT 同分布, 数学上这没有问题。

Few-step DMD 也可以是 (不妨命名为 Diffusion-type), $\mathbf{x}_{t-1} \sim \mathcal{N}(f_\theta(\mathbf{x}_t, t), \beta_t^2 \mathbf{I})$, 如此, 采样是 $T \rightarrow T-1 \rightarrow \dots \rightarrow 1 \rightarrow 0$ 。

换言之: Score Distillation 不是一个“建模方式”, 与模型参数化语义无关, 而是一个训练框架。

6.2 Consistency Models

本节介绍 Consistency Models.

6.2.1 Consistency Models

Consistency Models. 最初的 motivation 是构造一个直接映射 (而非概率分布的参数) $f_\theta(\mathbf{x}_t, t) \rightarrow \mathbf{x}_0 \sim p_{\text{data}}(\mathbf{x}_0)$. Naive 想法是训练

$$\theta^* = \min_{\theta} \mathbb{E}[\|f_\theta(\mathbf{x}_t, t) - \mathbf{x}_0\|^2], \quad (303)$$

其中 $\mathbf{x}_t \sim p_{\text{data}}(\mathbf{x}_t)$.

但根据 Remark 6.1.4, 这样学习到的是 $\mathbb{E}[\mathbf{x}_0 | \mathbf{x}_t]$, 显然不行。

现在假设存在可逆函数 $g(\text{data point}, \text{time from}, \text{time to}) : \mathbb{R}^{d \times 1 \times 1} \mapsto \mathbb{R}^d$, 考虑下面的优化目标:

$$\theta^* = \min_{\theta} \mathbb{E}[\|f_\theta(\mathbf{x}_t, t) - \mathbf{x}_0\|^2], \quad (304)$$

其中 $\mathbf{x}_t = g(\mathbf{x}_0, 0, t)$. 如此,

$$\mathbb{E}[\mathbf{x}_0 | \mathbf{x}_t] = g^{-1}(\mathbf{x}_t, t, 0), \quad (305)$$

$$f^*(\mathbf{x}_t, t) = g^{-1}(\mathbf{x}_t, t, 0) = \mathbf{x}_0. \quad (306)$$

那么 diffusion model 中是否存在这种可逆映射呢? 显然 PF-ODE 就是隐式的 g . 由此, 我们得出了训练目标:

$$\theta^* = \min_{\theta} \mathbb{E}_{\mathbf{x}_0, t}[\|f_\theta(\mathbf{x}_t, t) - \mathbf{x}_0\|^2], \quad (307)$$

其中 $\mathbf{x}_t = \text{PF-ODE}(\mathbf{x}_0, 0, t)$. 这种模型能够从任意 t 出发一步采样得到 reverse ODE 对应的 $\mathbf{x}_0 \sim p_{\text{data}}(\mathbf{x}_0)$. 一个理想策略是只训练 $t = T$ 然后一步生成。

然而这有一个问题: 对于 $\mathbf{x}_0$, 如何获得 $(\mathbf{x}_t, \mathbf{x}_0)$? 必须注意, $\hat{\mathbf{x}}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$ 并非所需, 这里与上文 $\theta^* = \min_{\theta} \mathbb{E}[\|f_\theta(\hat{\mathbf{x}}_t, t) - \mathbf{x}_0\|^2]$, $\hat{\mathbf{x}}_t \sim p_{\text{data}}(\hat{\mathbf{x}}_t)$ 别无二致, 只不过现在是 $\hat{\mathbf{x}}_t \sim p_{\text{data}}(\hat{\mathbf{x}}_t | \mathbf{x}_0)$ ⁵. 换言之 $\mathbf{x}_0$ 并不在 $\hat{\mathbf{x}}_t$ 所在的 (reverse) ODE 轨迹上: $\mathbf{x}_0 \xrightarrow{\text{forward SDE}} \hat{\mathbf{x}}_t \xrightarrow{\text{reverse ODE}} \hat{\mathbf{x}}_0, \quad \mathbf{x}_0 \neq \hat{\mathbf{x}}_0$.

⁵Tweedie formula: $f_\theta^*(\mathbf{x}_t, t) = \mathbb{E}[\mathbf{x}_0 | \mathbf{x}_t] = \frac{1}{\alpha_t} \left(\mathbf{x}_t + \sigma_t^2 \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t) \right)$, 这就是标准 diffusion models.